行人重识别

- Person re-identification要做什么

  - 在多摄像头的复杂场景中，快速定位查找指定目标的所有结果

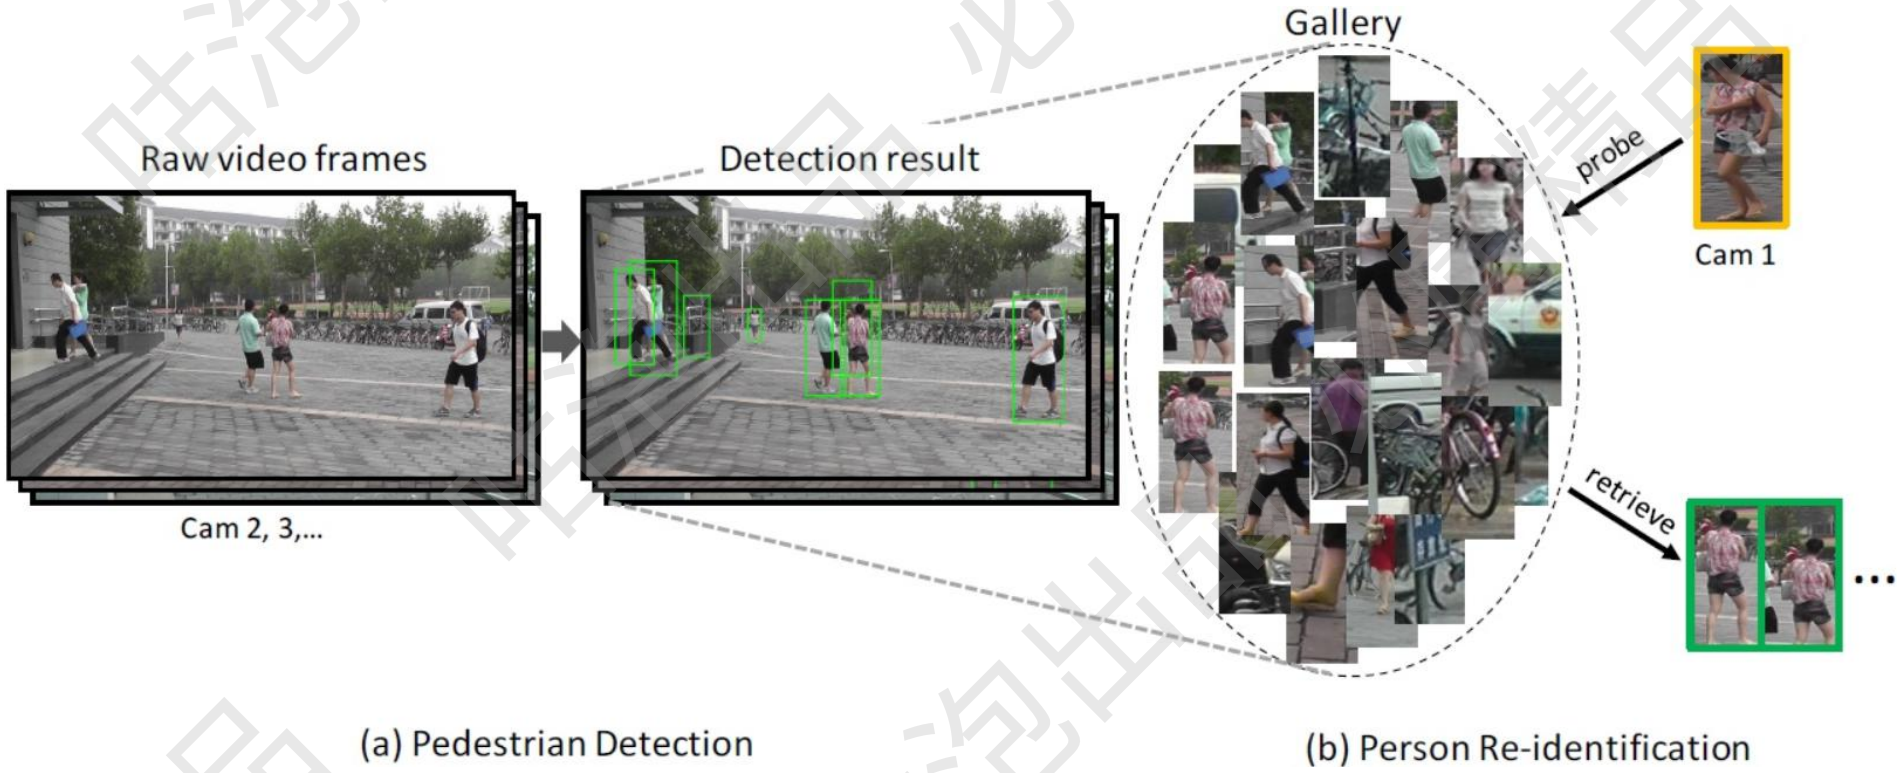

行人重识别

- 应用场景
  - 有人的地方就有江湖！
  - 一分钟我要他的所有信息！
  - 基本思想其实就是相似度匹配
  - 但是如何做的更好呢？

智能安防

智能商业—无人超市

人机交互

相册聚类

行人重识别

- 存在的挑战

- 如果只是相似度匹配，那就太简单了，这里面问题还挺多的！

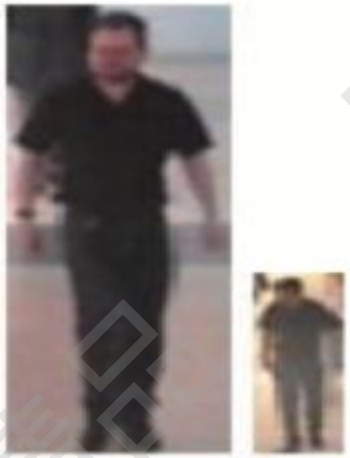

(a)低分辨率

(b)遮挡

(c)视角、姿势变化

(d)光照变化

(e)视觉模糊性

行人重识别

- 论文中常用数据集
  - CUHK03：香港中文大学（CUHK）校园
  - Market-1501 ： 清华大学校园
  - DukeMTMC：8 个摄像机
  - MSMIT17：12个室外和3个室内（校园）

Dataset	Identities	Cameras
Market1501	1501	6
DukeMTMC-reID	1812	8
CUHK03	1467	10(5 pairs)
MSMT17	4101	15

行人重识别

- 论文中常用数据集

  - DukeMTMC数据集，基本都是把视频经过行人检测处理成输入和标签

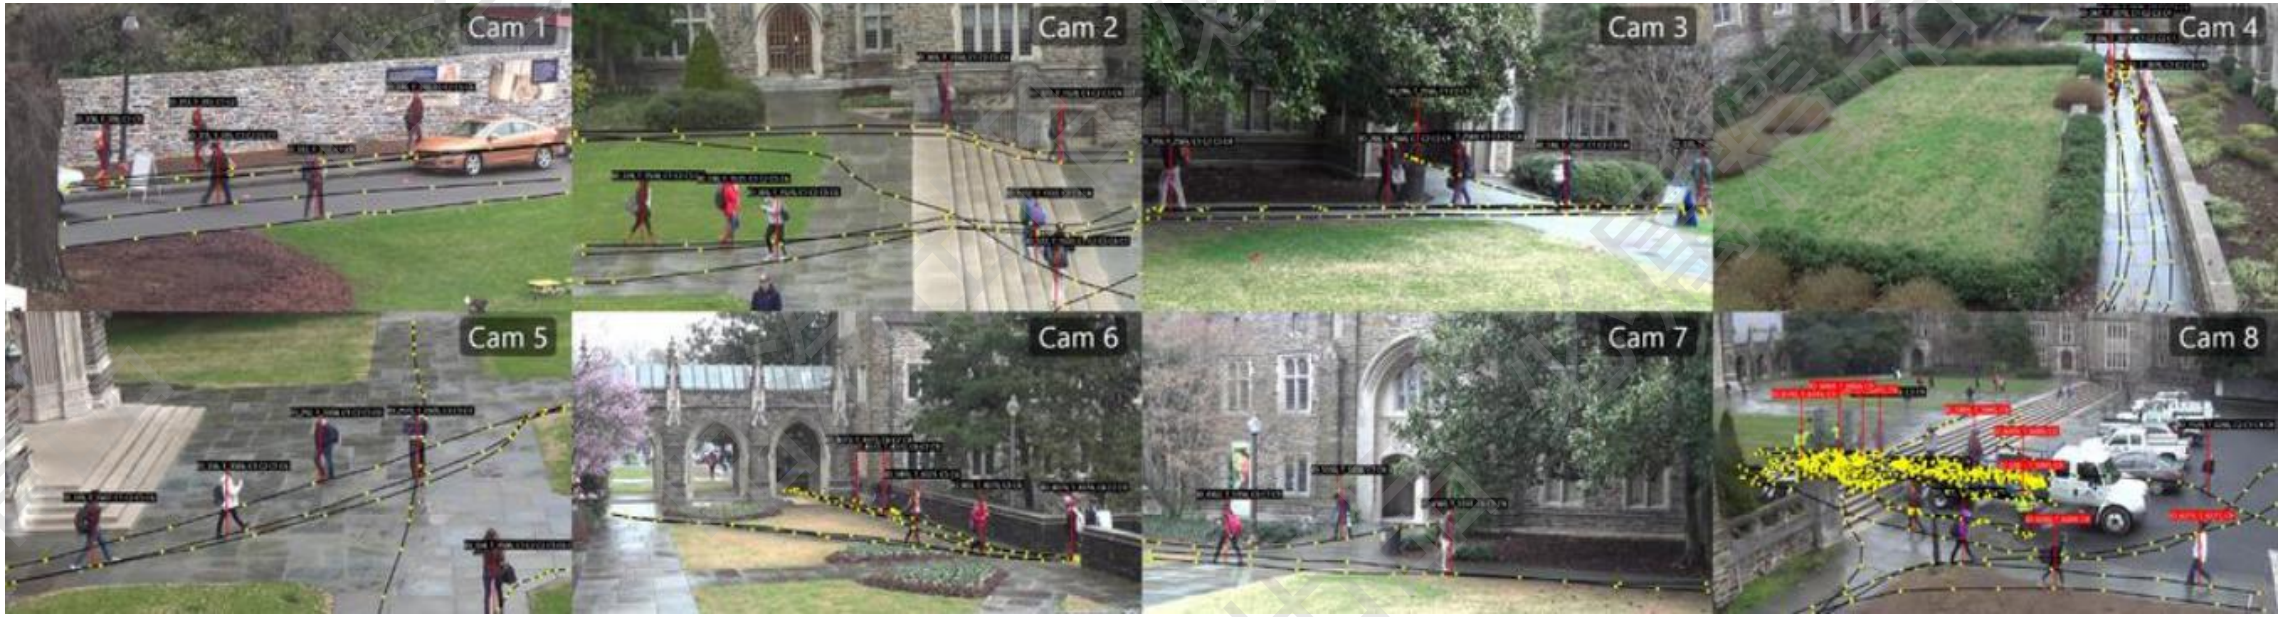

行人重识别

- 评估标准
  - 基本所有论文都会提到这两个概念：rank1和map值
  - 返回结果中包含了一系列的图像，rank1指的是第一张结果正确

行人重识别

- Map值计算

  - map要计算多次输入的综合ap结果，每张测试图像计算如下：

  - ap（1+2/3+3/6+4/9+5/10）也就是一张正确图像本应该是第几个

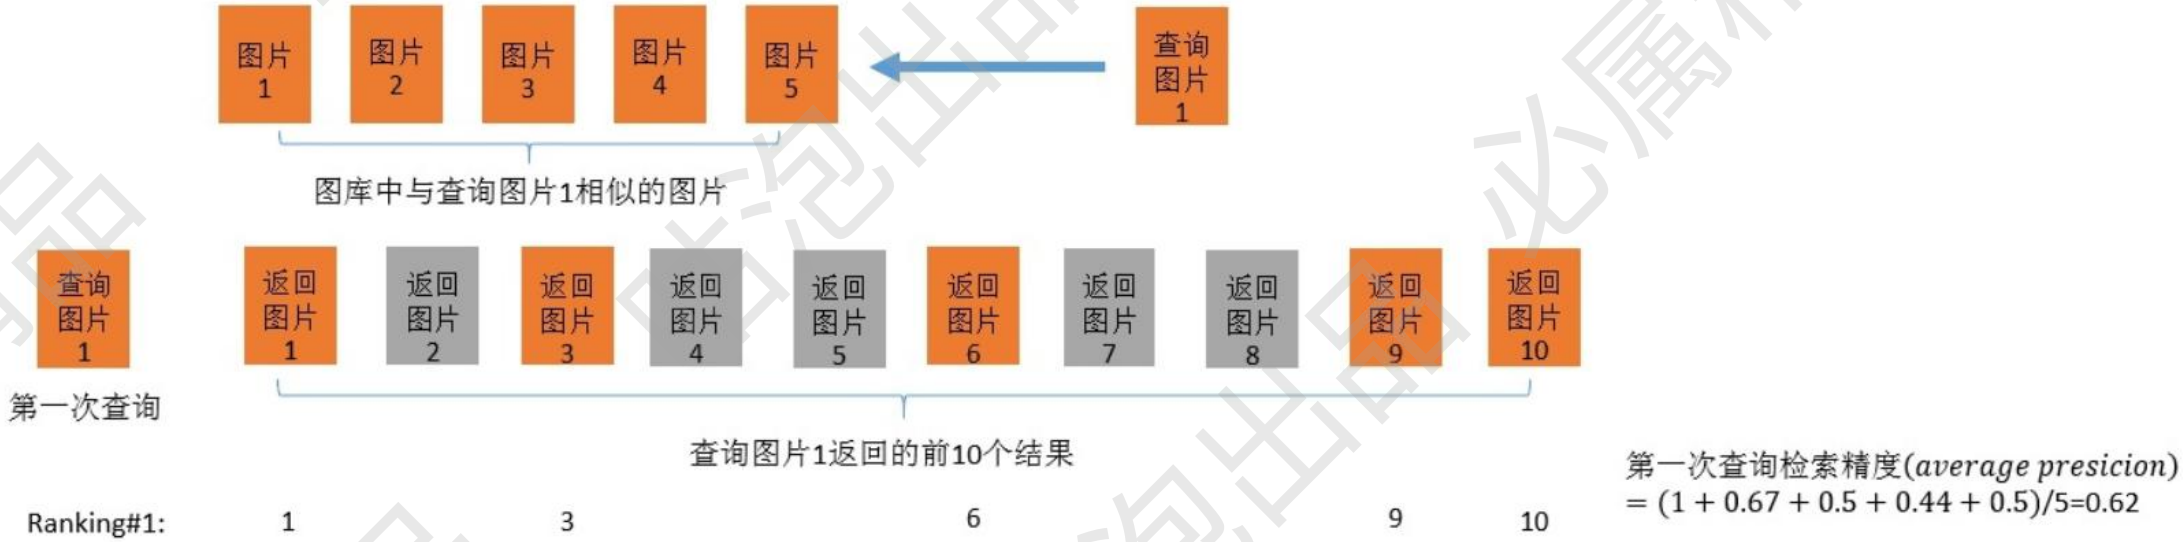

行人重识别

- Map值计算

  - 举例：两个测试数据，ap分别为0.62，0.44则map=(0.62+0.44)/2=0.53

  - ap（1/2+2/5+3/7）也就是一张正确图像本应该是第几个

行人重识别

- 损失函数定义

  - 通常是分类损失+Triplet loss（目标其实就是为了让特征提取的更好）

  - Triplet loss需要准备3份数据（可以从一个batch中选择）
    其中Anchor表示当前数据，Positive是跟A相同人的数据，Negative是不同人的数据。

行人重识别

- Triplet loss
  - 分别对3份数据进行编码
  - 这三兄弟经过的网络是一样的
  - 然后计算他们之前的差异
  - 通过差异值来更新权重参数

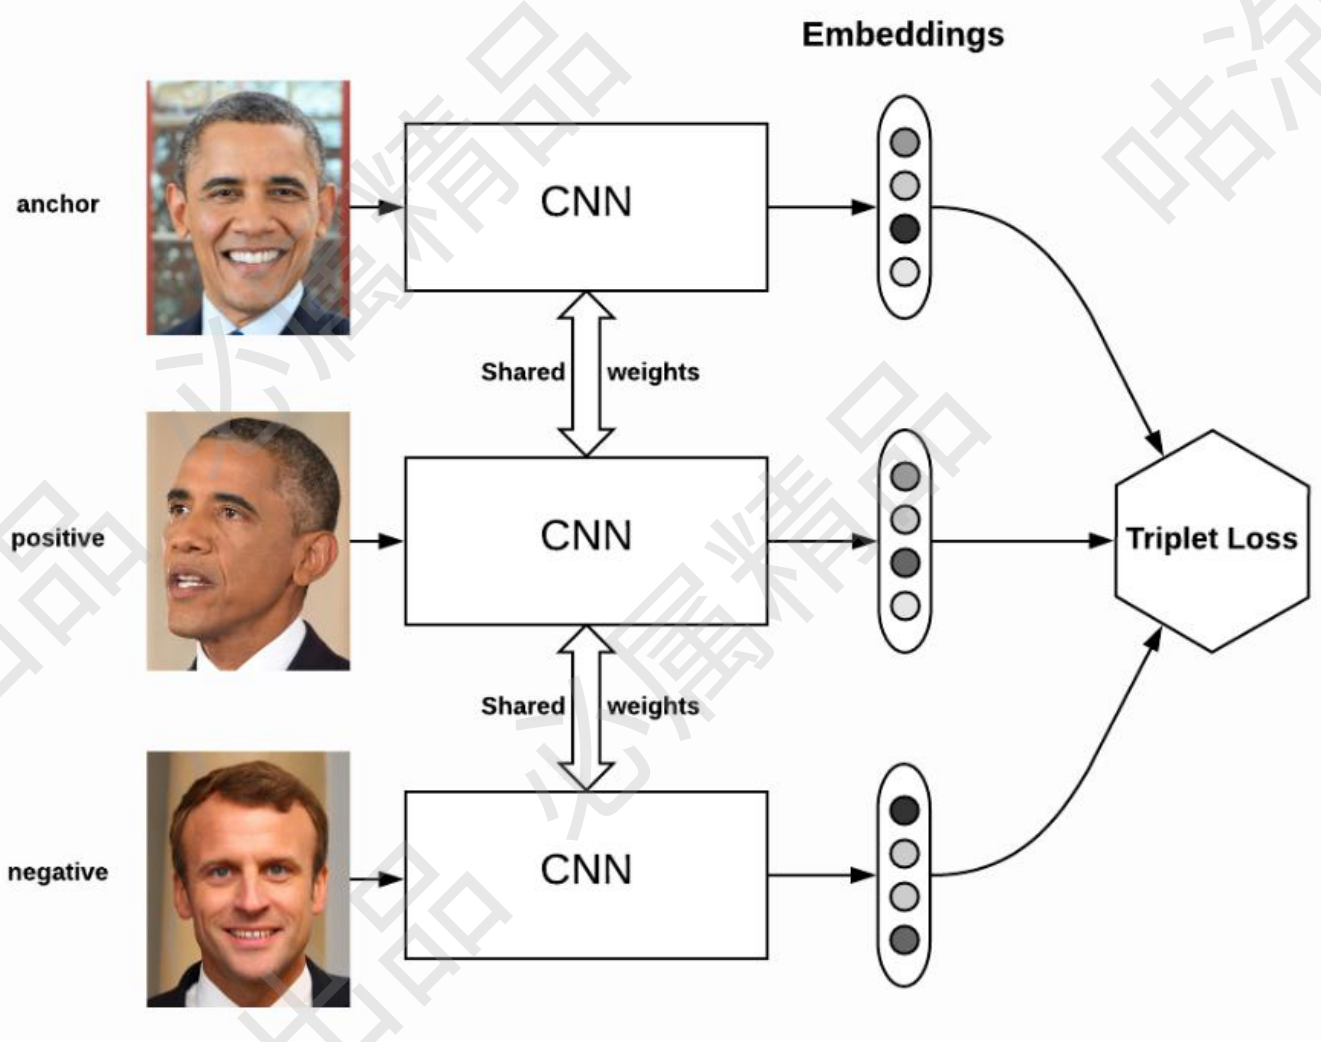

行人重识别

- Triplet loss

  - 目的其实很简单，只需让A跟P非常接近，A与N尽可能远离

  - 公式：$||f(A)-f(P)||^2 \leq ||f(A)-f(N)||^2$ 其中f表示通过网络进行编码

  - 是否会存在问题呢？如果f把所有的输入都编码成0，依旧成立！

  - 那这个目标得重新修改一下：$\|f(A)-f(P)\|^2 - \|f(A)-f(N)\|^2 + a \leq 0$
    (其中a通常叫做margin，也就是间隔，表示d(A,P) 与d(A,N)至少得相差多少)

行人重识别

- Triplet loss

  - Triplet loss：$L(A,P,N)=\max(\|f(A)-f(P)\|^2-\|f(A)-f(N)\|^2+a,0)$

  - 但是对于约束条件：d(A,P)+a≤d(A,N)，这件事很难嘛？
    理论上都是A与P很近，A与N较远，这还需要学嘛。。。

  - 实际中用的最多的是hard negative方法，也就是在选择样本的时候：
    让d(A,P)≈d(A,N) ,这样给网络一些挑战，才能刺激它来学习！

行人重识别

- 使用resnet构建基本网络架构

- 论文中大部分都是基于resnet50来进行特征提取

layer name	output size	18-layer	34-layer	50-layer	101-layer	152-layer
conv1	112×112	7×7, 64, stride 2				
		3×3 max pool, stride 2				
conv2_x	56×56	[3×3, 64; 3×3, 64] ×2	[3×3, 64; 3×3, 64] ×3	[1×1, 64; 3×3, 64; 1×1, 256] ×3	[1×1, 64; 3×3, 64; 1×1, 256] ×3	[1×1, 64; 3×3, 64; 1×1, 256] ×3
conv3_x	28×28	[3×3, 128; 3×3, 128] ×2	[3×3, 128; 3×3, 128] ×4	[1×1, 128; 3×3, 128; 1×1, 512] ×4	[1×1, 128; 3×3, 128; 1×1, 512] ×4	[1×1, 128; 3×3, 128; 1×1, 512] ×8
conv4_x	14×14	[3×3, 256; 3×3, 256] ×2	[3×3, 256; 3×3, 256] ×6	[1×1, 256; 3×3, 256; 1×1, 1024] ×6	[1×1, 256; 3×3, 256; 1×1, 1024] ×23	[1×1, 256; 3×3, 256; 1×1, 1024] ×36
conv5_x	7×7	[3×3, 512; 3×3, 512] ×2	[3×3, 512; 3×3, 512] ×3	[1×1, 512; 3×3, 512; 1×1, 2048] ×3	[1×1, 512; 3×3, 512; 1×1, 2048] ×3	[1×1, 512; 3×3, 512; 1×1, 2048] ×3
	1×1	average pool, 1000-d fc, softmax				
FLOPs		1.8×10^9	3.6×10^9	3.8×10^9	7.6×10^9	11.3×10^9

行人重识别

- Relation Network for Person Re-identification
  - 如何更好的利用图像中的信息呢?
  - 通常都是对整个输入数据进行特征提取，但是缺少了局部信息
  - 如果把图像分成几个区域（头，身子，腿。。），这样可能又太散了
  - 能不能既考虑局部与整体信息，也同时加入他们的联系呢?

行人重识别

- Relation Network for Person Re-identification

  - 整体流程分析：

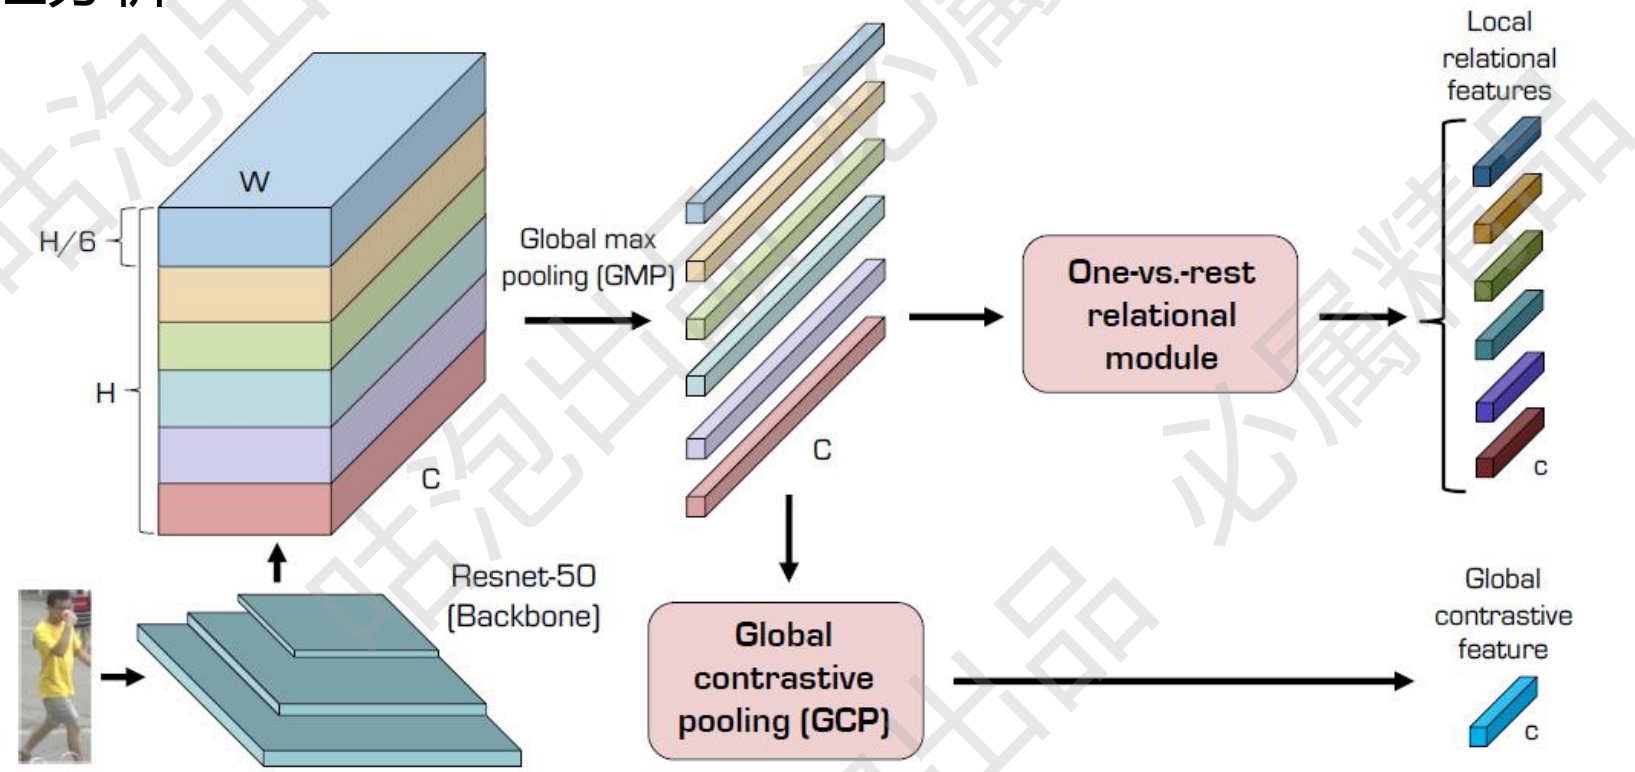

行人重识别

- Relation Network for Person Re-identification
  - 步骤1：首先对整体进行特征提取
  - 先将输入数据resize，然后输入到resnet中
  - 基本所有的ReID模型都是先进行这一步
  - 加载imagenet预训练的resnet50模型

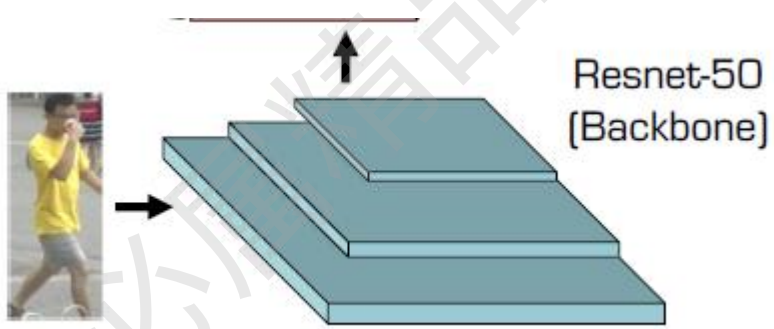

行人重识别

- Relation Network for Person Re-identification

  - 步骤2：将特征图分块
  - 直接在h维度进行截取，并没有利用其它辅助信息
  - 为什么是6个呢？4个不行吗？
  - 为了得到更综合的特征，源码分了三组实验（1/6h，1/4h，1/2h）

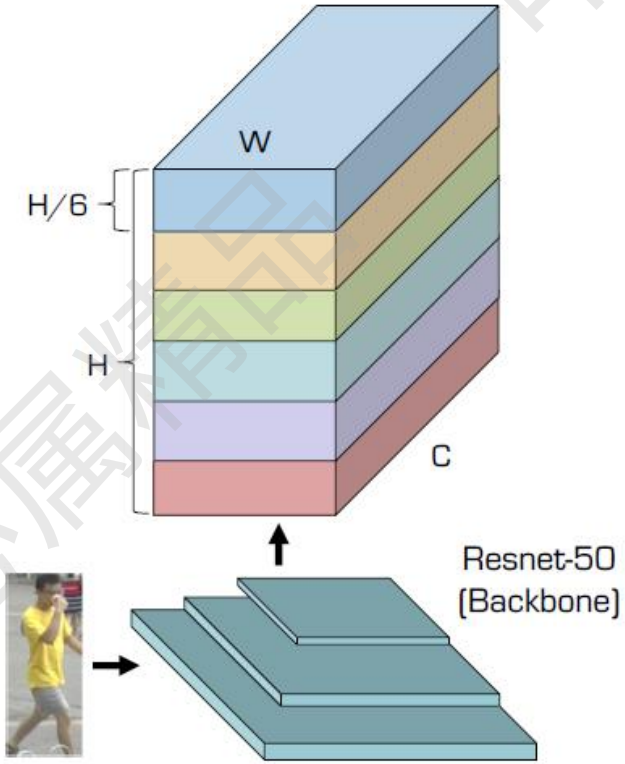

行人重识别

- Relation Network for Person Re-identification

  - 步骤3：计算GCP特征，
  - avgPool会引入局部与背景信息
  - 差异特征更好描述局部关系

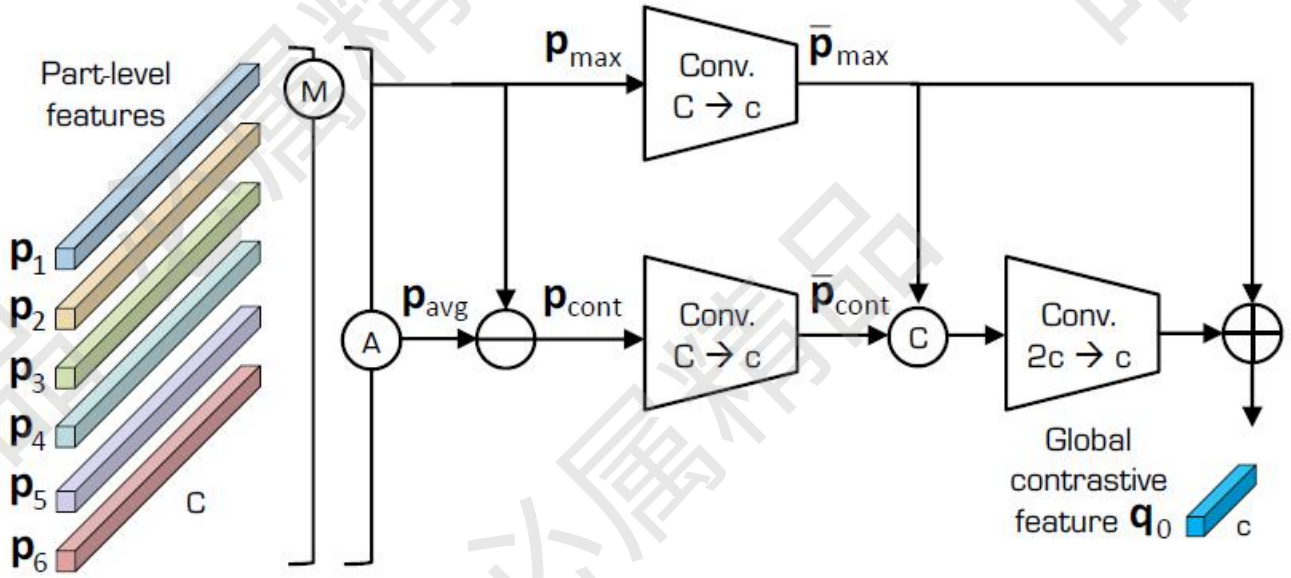

  - 一定程度上去掉了一些噪音特征的干扰（有待其它领域算法来证明。。。）

行人重识别

- Relation Network for Person Re-identification

  - GAP相当于全局都有了，GMP相当于最核心那一块。

  - GCP之后相当于各个关键点的信息了（contrastive）

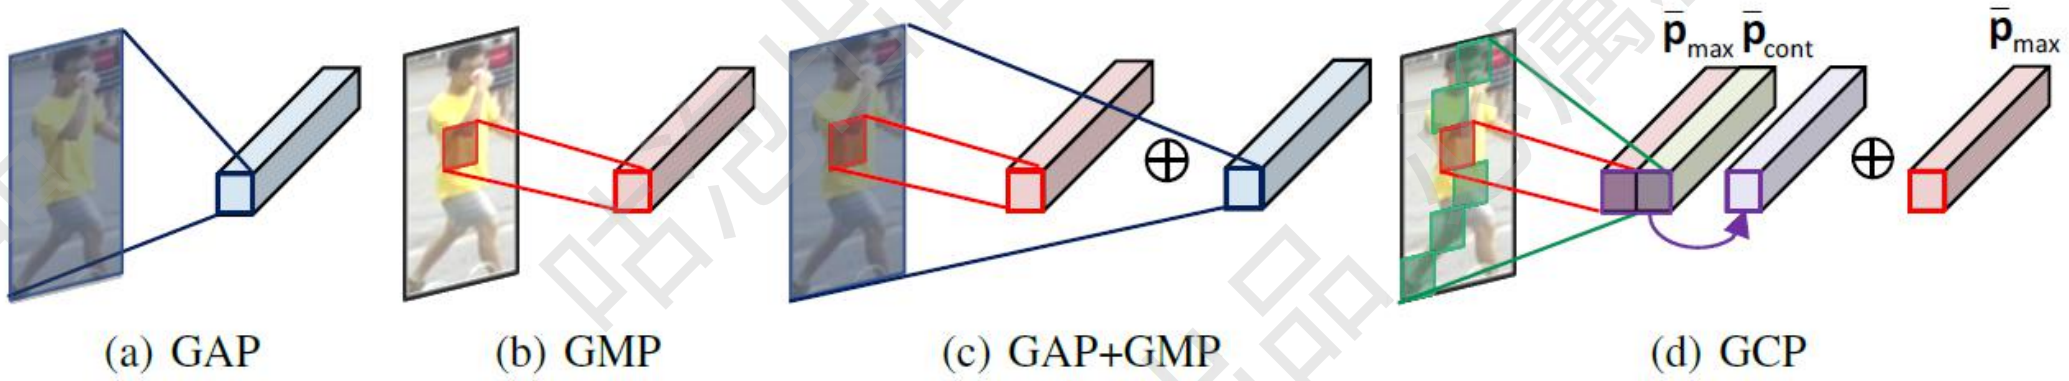

(a) GAP (b) GMP (c) GAP+GMP (d) GCP

行人重识别

- Relation Network for Person Re-identification

  - 步骤4：one vs rest
  - 有多少种组合呢？都要算的！
  - 出发点就是别把局部信息孤立来算
  - 其实有点类似attention的方法

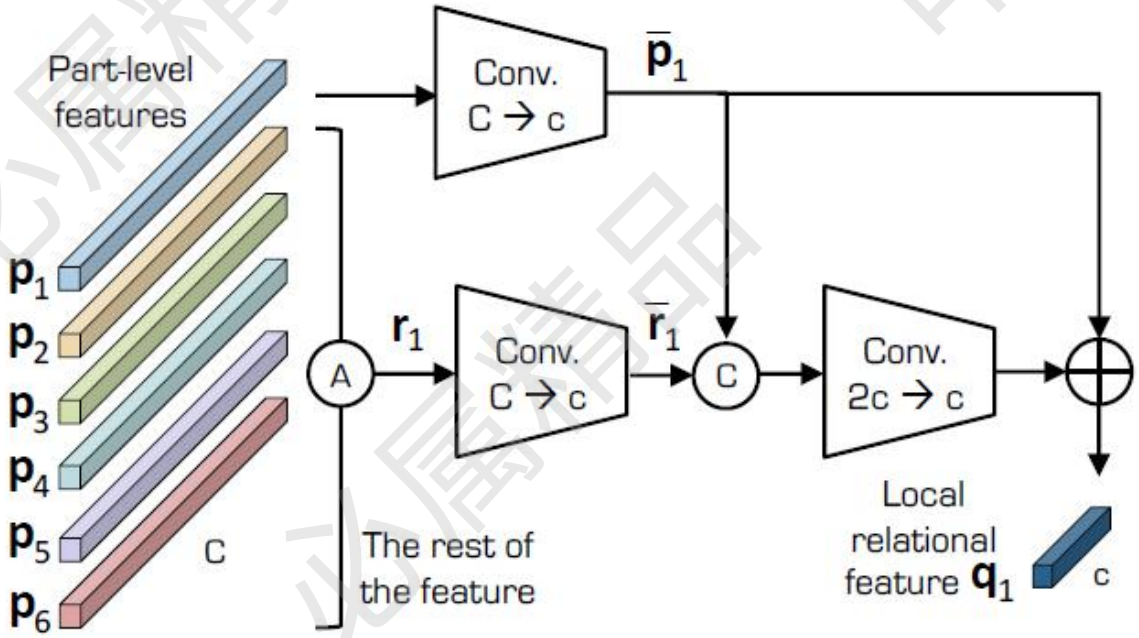

行人重识别

- Relation Network for Person Re-identification

  - 步骤4：损失函数

  - 还是那兄弟俩，分类损失和triplet loss，但是好多地方都去凑热闹

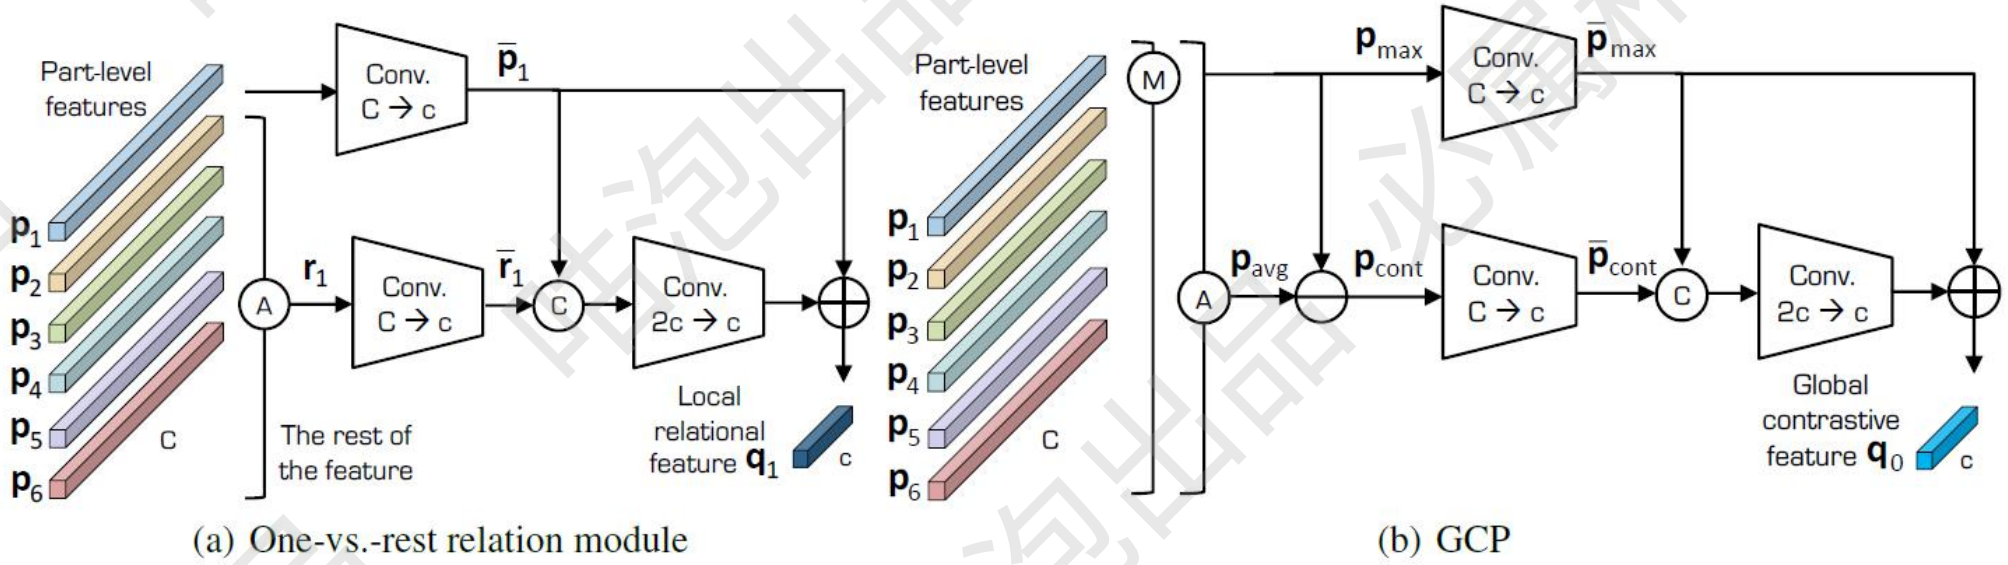

(a) One-vs.-rest relation module (b) GCP

行人重识别

- Learning Relation and Topology for Occluded Person Re-Identification

  - 听这名字，应该就能看出来他主要解决遮蔽现象

  - 数据重构，Occluded-DukeMTMC（query里全是遮蔽现象的数据）

  - 提出了三阶段的模型：1.关键点局部特征提取；2.图卷积融合关键点特征；3.基于图匹配的方式来计算相似度并训练模型。

  - 整体思路相当可以！这招在各种跟验证相关的任务中都可以套（人脸验证）

行人重识别

- Learning Relation and Topology for Occluded Person Re-Identification

总结起来就是分三阶段来完成特征提取，重点要解决遮蔽现象的局部特征

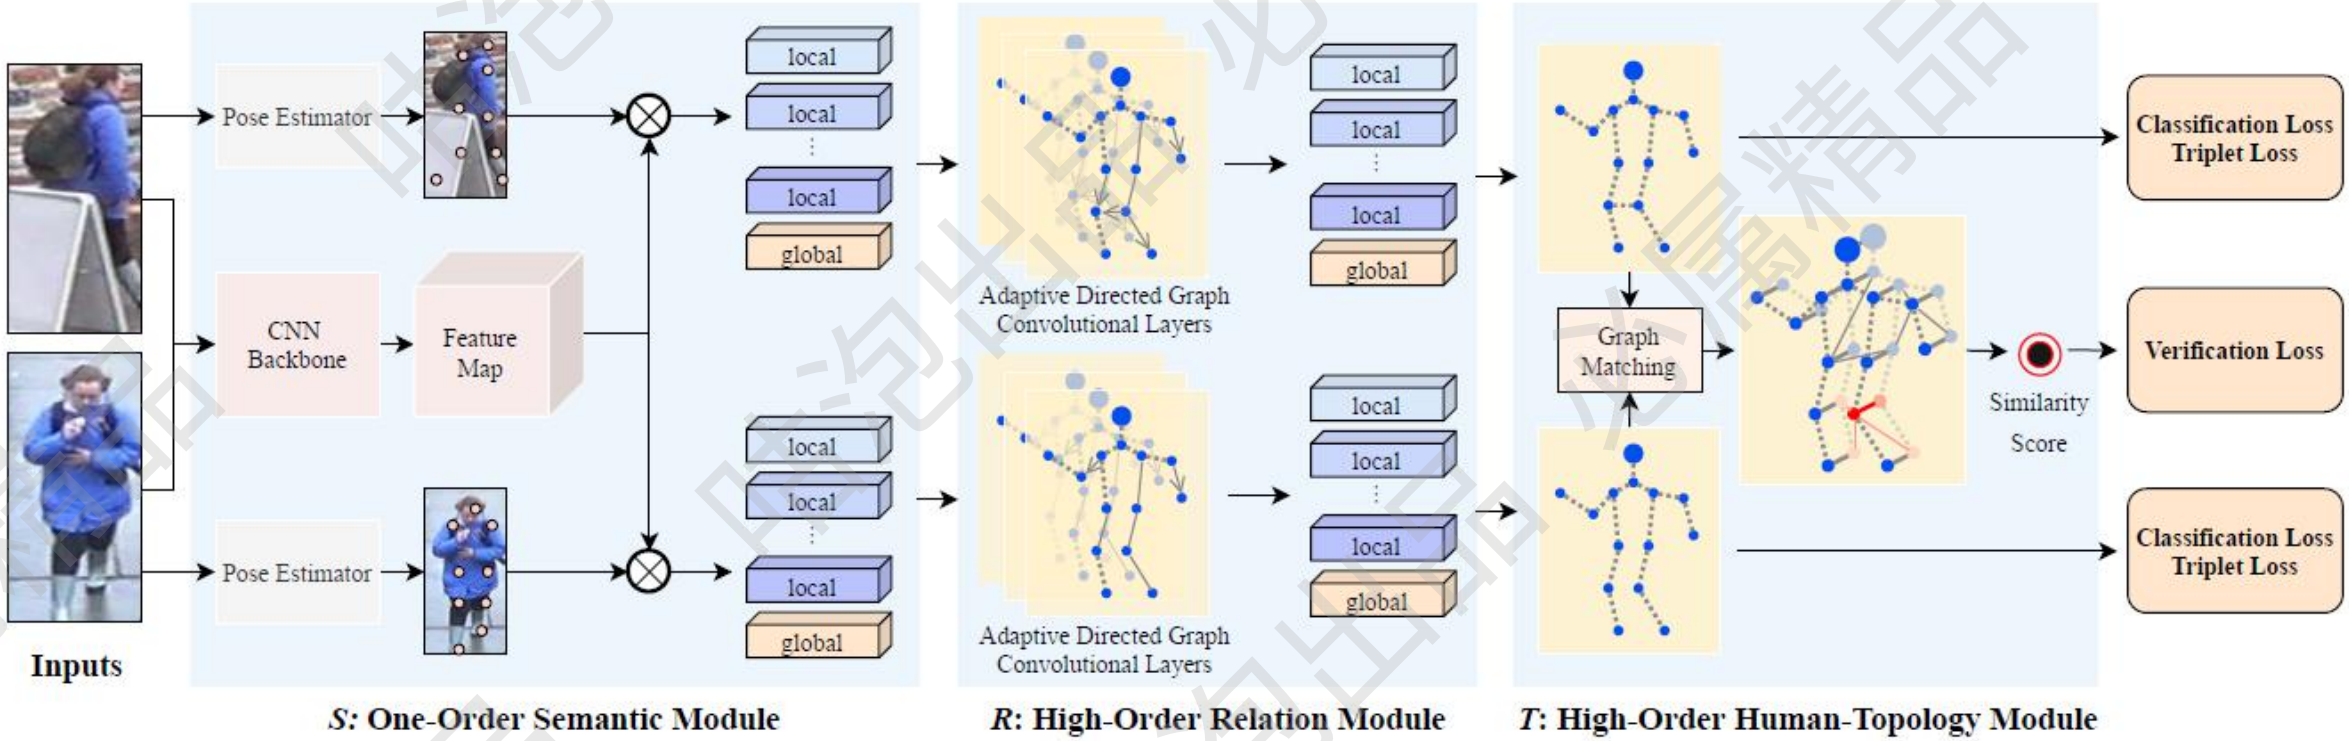

行人重识别

- Learning Relation and Topology for Occluded Person Re-Identification

  - 一阶段：关键点局部特征提取
  - 选择一个pose estimation模型即可
  - 得到的是各个关键点的热度图信息
  - 通过热度图得到原始特征图的局部特征

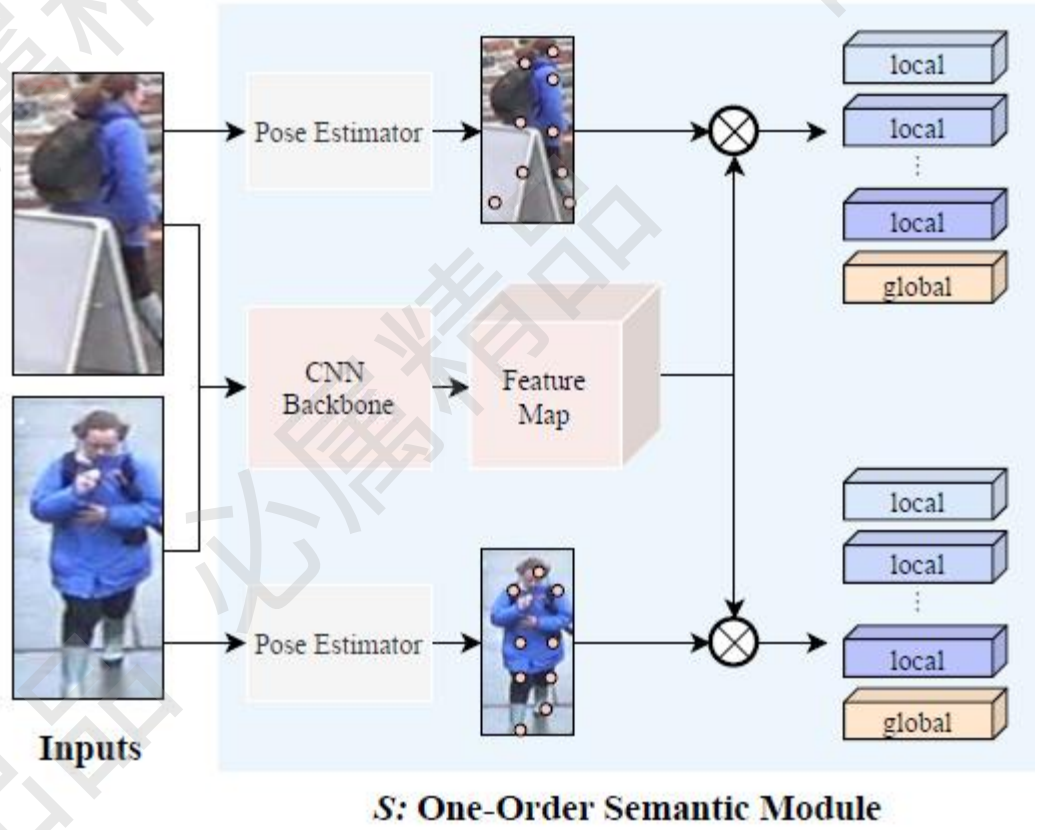

S: One-Order Semantic Module

行人重识别

- Learning Relation and Topology for Occluded Person Re-Identification
  - 其实就是一个乘法操作，用pose estimation得到的热度图来计算局部特征
  - 左图可以当做是 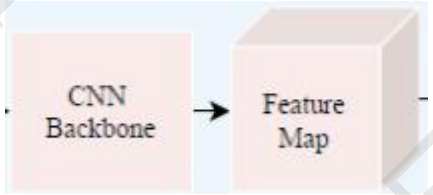

，右图就是其关键点信息的热度图

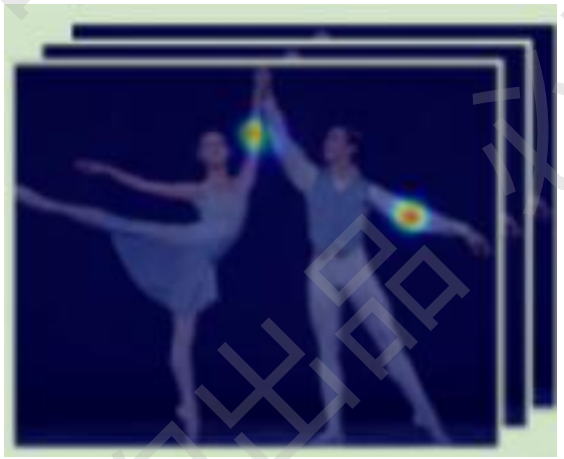

行人重识别

- Learning Relation and Topology for Occluded Person Re-Identification

  - 一阶段：关键点局部特征提取
  - 跟上篇算法一样这里同样也加了多个损失
  - local与global的都需要进行训练
  - 全部特征是global average pooling得到

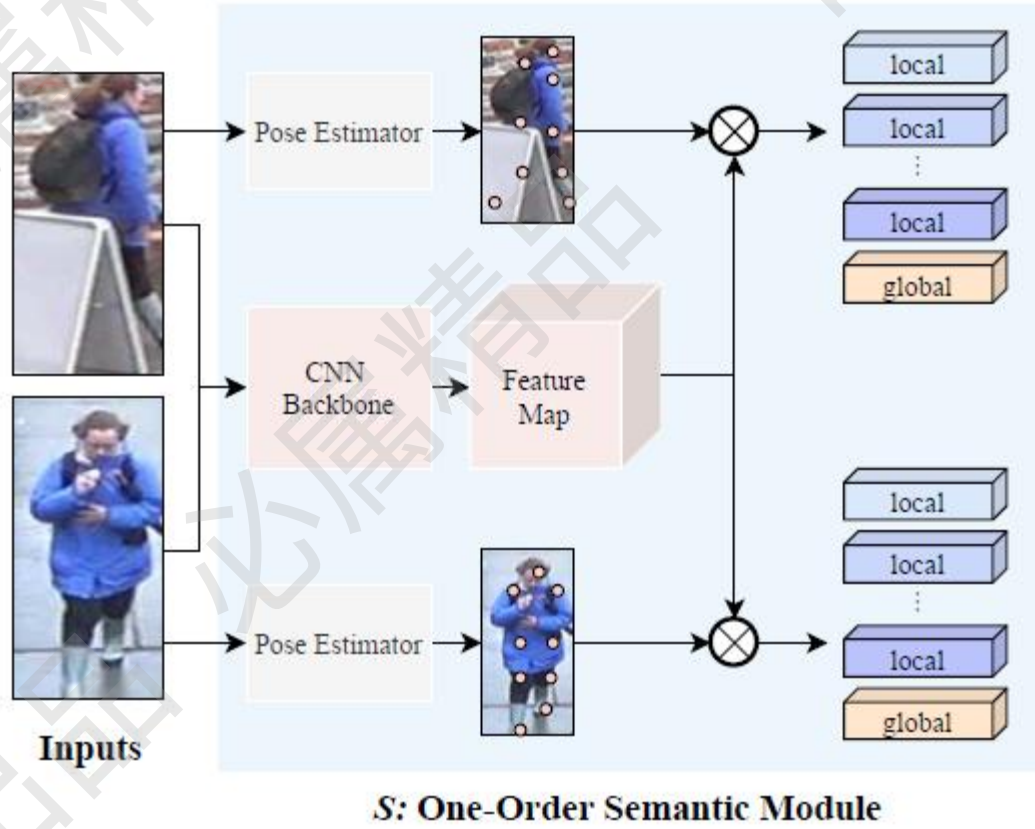

S: One-Order Semantic Module

行人重识别

- Learning Relation and Topology for Occluded Person Re-Identification

  - 二阶段：局部特征关系整合（图卷积）
  - 如何才能更好的利用局部特征呢？加入关系！
  - 先初始化邻接矩阵来进行图卷积
  - 邻接矩阵在学习过程中更新（如何才能更好的针对每个输入利用不同的局部特征）

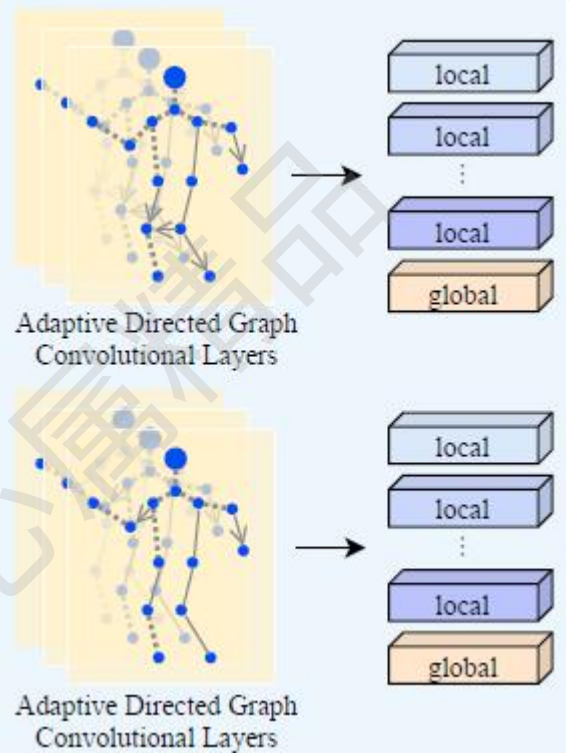

行人重识别

- Learning Relation and Topology for Occluded Person Re-Identification

  - 图卷积怎么做呢？其实总结起来就是如何利用各个点的特征。

  - 这个任务中，就是得到邻接矩阵A来指导每个关键点特征如何跟其他关键点特征进行计算，并且A矩阵也要进行学习！

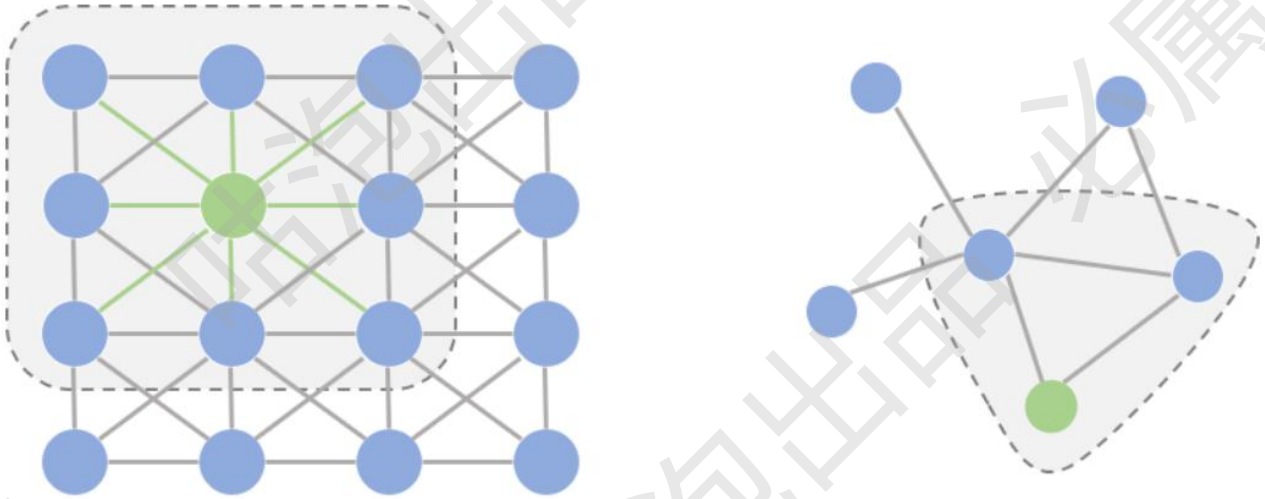

行人重识别

- Learning Relation and Topology for Occluded Person Re-Identification

  - 二阶段：局部特征关系整合（图卷积）

  - 和整体特征差异越大的，越离群

  - 利用差异特征来学习邻接矩阵A

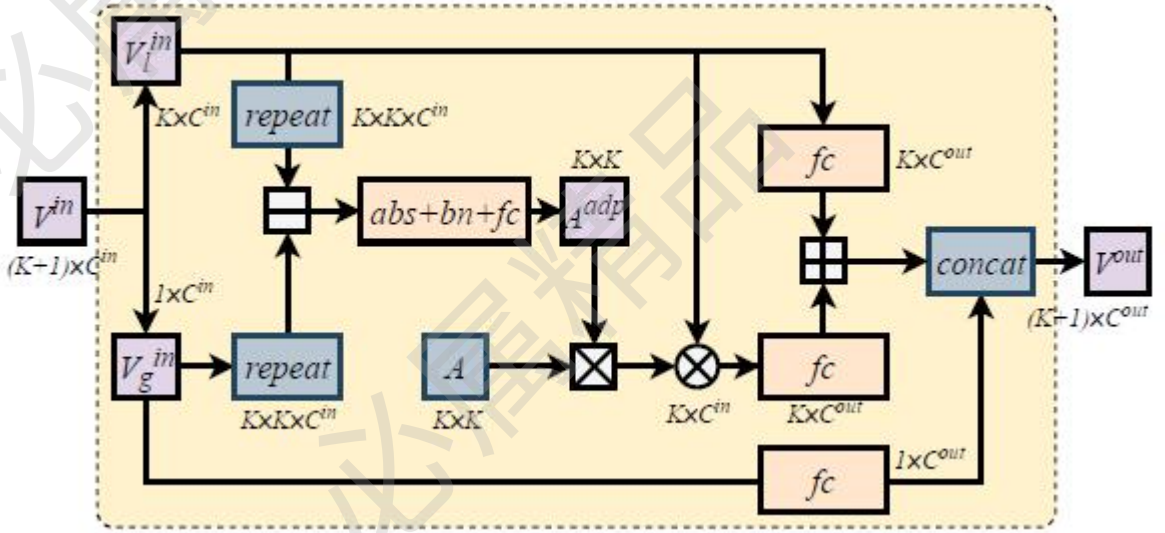

  - 有了A就能开始图卷积啦，用它来指导如何利用不同关键点的特征进行组合最终再与输入的局部特征进行整合。

行人重识别

- Learning Relation and Topology for Occluded Person Re-Identification

  - 三阶段：图匹配
  - 如何才能训练的更好呢？还是AP,AN问题！
  - 输入两张图像（经过了前两阶段后的结果）
  - 计算他们之间的相似度
    （其实输入是两组，第一组A,P；第二组，A,N；）

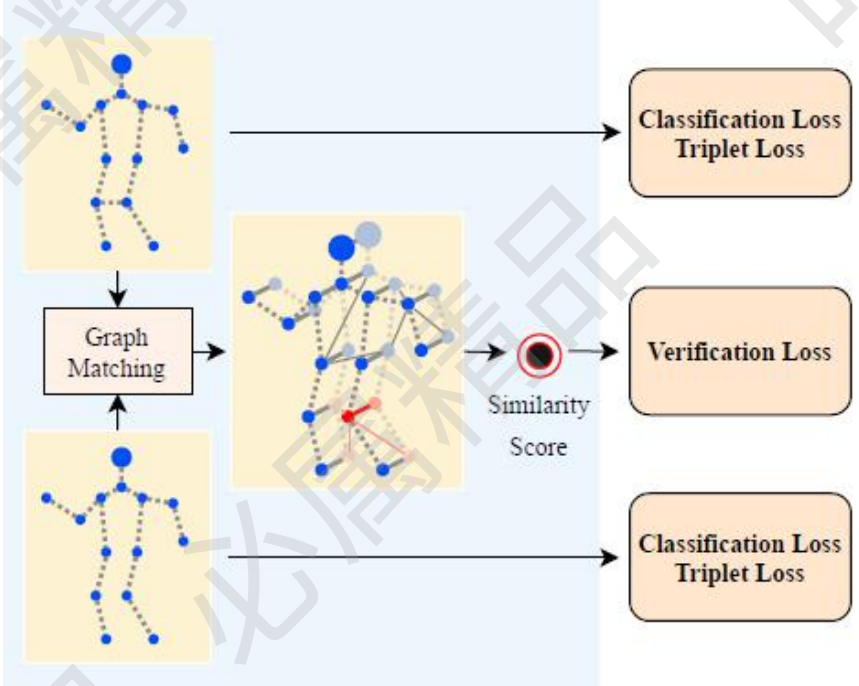

行人重识别

- Learning Relation and Topology for Occluded Person Re-Identification

  - 三阶段：图匹配
  - 图匹配就是要一个相似度矩阵U
  - 例如14*14，表示两个图之间的关系

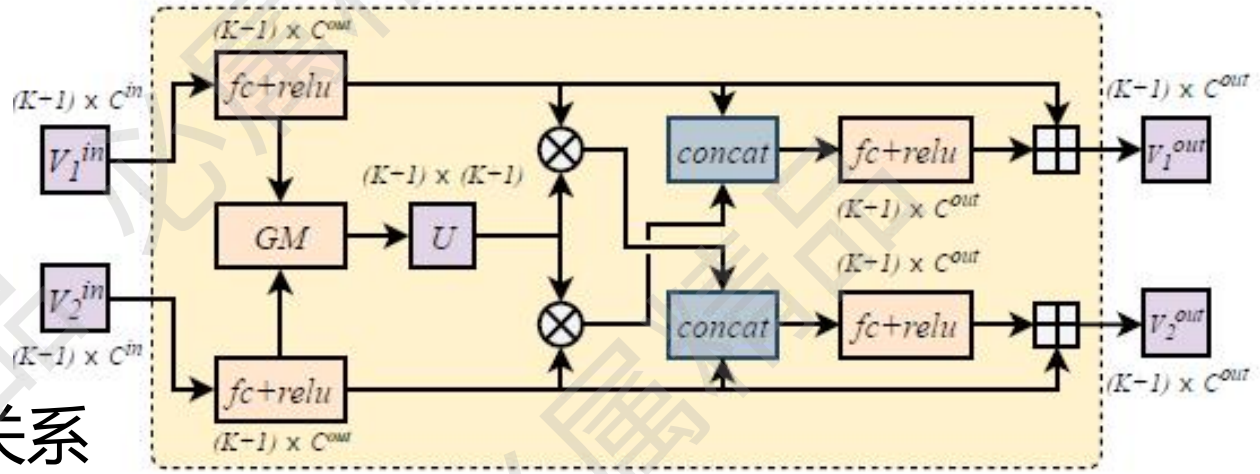

  - 注意这里面是一个交叉的过程(cross)，分别交叉来得到各自匹配的特征结果

行人重识别

- Learning Relation and Topology for Occluded Person Re-Identification

  - 三阶段：图匹配
  - 还引入了新的损失函数:验证损失
  - 就是sigmoid(emb1,emb2)的结果

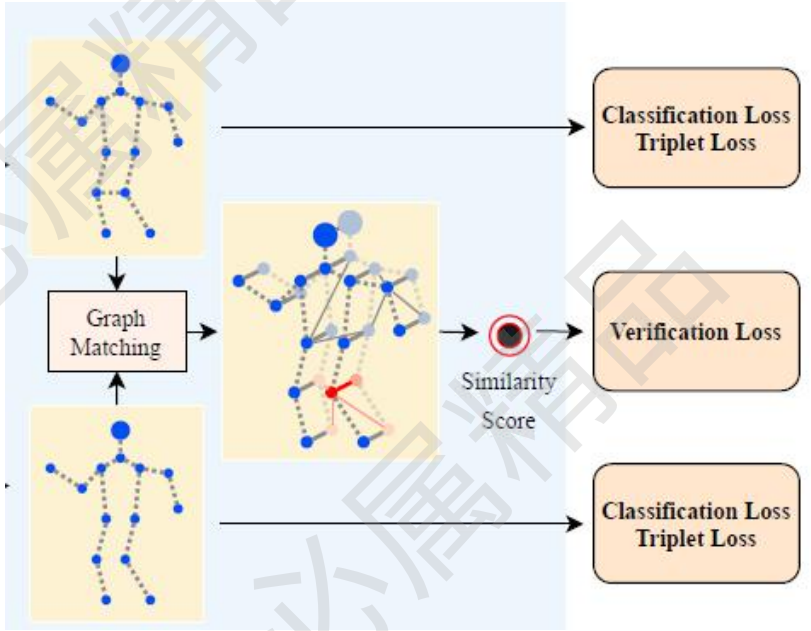

- 整体框架知识点涉及比较多，可以说本届CVPR中比较值得一看的！